

Laporan Praktikum Preprocessing dan Normalisasi

Nama : Surya Dwi Satria
Kelas : C7
NIM : 434231048

Tujuan Praktikum

Melakukan preprocessing (missing value, duplikat, outlier) dan normalisasi menggunakan tiga metode: Simple Feature Scaling, Min-Max, dan Z-Score. Dataset berisi profil pelanggan ritel: usia, pendapatan, skor belanja, masa bergabung, jumlah transaksi, dan nilai keranjang rata-rata, serta kategori (gender, kota).

Langkah preprocessing:

1. Menghapus duplikat baris.
2. Mengisi nilai hilang: median untuk numerik, modus untuk kategorikal.
3. Menangani outlier dengan teknik IQR capping (clipping berdasarkan $Q1 \pm 1.5 * IQR$).
4. One-Hot Encoding untuk variabel kategorikal.

Normalisasi/Standarisasi:

- Simple Feature Scaling: $x / \max(x)$
- Min-Max Scaling: $(x - \min) / (\max - \min)$
- Z-Score: $(x - \text{mean}) / \text{std}$

Visualisasi Data

Visualisasi histogram distribusi fitur dilakukan sebelum dan sesudah scaling untuk fitur utama: Age, AnnualIncome, SpendingScore, TenureYear.

Hasil:

- Setelah preprocessing, data bersih dari duplikasi dan nilai hilang.
- Outlier ekstrem berhasil ditahan (capping) sehingga skala fitur lebih stabil.
- Min-Max mengubah rentang ke 0..1, baik untuk model berbasis jarak.
- Z-Score menstandarkan $\text{mean} \approx 0$ dan $\text{std} \approx 1$, cocok untuk model linier/statistik.
- Simple Feature Scaling relatif sederhana dan cepat tetapi tidak mempertahankan distribusi.

Rekomendasi: pilih teknik sesuai algoritme. Untuk K-Means/KNN gunakan Min-Max; untuk regresi/logistic/PCA gunakan Z-Score.

Pengerjaan :

1. Inisialisasi library di notebook jupyter, dan memanggil data

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
df = pd.read_csv("shopping_data.csv")
df
```

CustomerID Gender City Age AnnualIncome SpendingScore TenureYear NumTransactions AvgBasketValue
0 1 Male Greek 18.0 15.9 67.0 6.2 12.0 298.00
1 2 Female Greek 19.0 44.0 59.0 5.3 9.0 210.38
2 3 Female Surabaya 26.0 18.9 NaN 8.0 15.0 190.63
3 4 Female Surabaya 30.0 64.5 17.0 3.9 7.0 125.28
4 5 Male Surabaya 31.0 75.6 59.0 10.1 13.0 118.11
...
218 219 Female Malang 41.0 91.8 64.0 2.6 8.0 225.00
219 220 Female Surabaya 28.0 107.4 58.0 3.7 9.0 210.57
220 92 Female Surabaya NaN 74.3 54.0 1.7 8.0 201.06
221 35 Female Surabaya 24.0 97.7 40.0 7.3 9.0 254.03
222 106 Male Malang 41.0 12.8 60.0 4.9 8.0 20.14

2. Statistik deskriptif data data shopping

```
df.describe(include='all').T  
0.0s
```

	count	unique	top	freq	mean	std	min	25%	50%	75%	max
CustomerID	223.0	NaN	NaN	NaN	110.058296	63.435228	1.0	55.5	109.0	164.5	220.0
Gender	223	2	Female	115	NaN	NaN	NaN	NaN	NaN	NaN	NaN
City	223	5	Surabaya	73	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Age	217.0	NaN	NaN	NaN	31.930876	8.842229	16.0	25.0	32.0	38.0	60.0
AnnualIncome	218.0	NaN	NaN	NaN	77.216972	41.015753	10.0	53.675	75.5	94.45	388.2
SpendingScore	218.0	NaN	NaN	NaN	52.293578	18.663058	2.0	39.25	53.0	64.0	99.0
TenureYear	218.0	NaN	NaN	NaN	4.169266	2.879823	0.1	2.0	3.45	5.575	14.8
NumTransactions	218.0	NaN	NaN	NaN	7.90367	2.812888	2.0	6.0	8.0	10.0	16.0
AvgBasketValue	218.0	NaN	NaN	NaN	184.176697	95.741641	20.14	141.895	173.9	216.46	1051.16

Penjelasan :

count → jumlah data valid (tidak NaN).

mean → rata-rata.

std → standar deviasi (sebaran data).

min → nilai terkecil.

25% → kuartil bawah (Q1).

50% → median (Q2).

75% → kuartil atas (Q3).

max → nilai terbesar.

3. Cek Mising value dan duplikat

```
df.isna().sum()  
0.0s
```

CustomerID	0
Gender	0
City	0
Age	6
AnnualIncome	5
SpendingScore	5
TenureYear	5
NumTransactions	5
AvgBasketValue	5
dtype: int64	

```
df.duplicated().sum()  
0.0s
```

np.int64(0)

Penjelasan : terdapat missing value di kolom kolom yang di tujuhan di output dan tidak ditemukan duplikat data

4. Imputasi missing value

```
num_cols = df.select_dtypes(include=['float64', 'int64']).columns.tolist()
cat_cols = df.select_dtypes(include=['object']).columns.tolist()

for c in num_cols:
    df[c] = df[c].fillna(df[c].median())

for c in cat_cols:
    df[c] = df[c].fillna(df[c].mode().iloc[0])

df.isna().sum()
✓ 0.0s

CustomerID      0
Gender          0
City            0
Age             0
AnnualIncome    0
SpendingScore   0
TenureYear      0
NumTransactions 0
AvgBasketValue  0
dtype: int64
```

Penjelasan : Mengambil semua kolom yang bertipe data numerik lalu dimasukan dalam kolom list, mengambil semua kolom yang bertipe string atau text dimasukan dalam kolom list.

- $df[c] = df[c].fillna(df[c].median()) \rightarrow$ mengisi data yang kosong dengan median dari semuaa data yang ada di kolom tersebut
- $df[c] = df[c].fillna(df[c].mode().iloc[0]) \rightarrow$ mengisi data yang kosong dengan modus / atau nilai yang paling sering muncul di kolom tersebut

5. Menangani Outlier (Capping IQR)

```
def iqr_cap(series, k=1.5):
    q1 = series.quantile(0.25)
    q3 = series.quantile(0.75)
    iqr = q3 - q1
    lower = q1 - k*iqr
    upper = q3 + k*iqr
    return series.clip(lower, upper)

num_cols_wo_id = [c for c in num_cols if c != "CustomerID"]
df[num_cols_wo_id] = df[num_cols_wo_id].apply(iqr_cap)

df.describe().T
✓ 0.0s

   count      mean       std      min     25%     50%     75%      max
CustomerID  220.0  110.500000  63.652704  1.00000  55.7500  110.50  165.250  220.00000
Age         220.0  31.907386  8.684278  16.00000  25.0000  32.00  37.250  55.62500
AnnualIncome 220.0  75.392045  30.669780 10.00000  53.9000  75.60  94.000  154.15000
SpendingScore 220.0  52.328977  18.534872  3.37500  39.7500  53.00  64.000  99.00000
TenureYear   220.0  4.074716  2.652479  0.10000  2.0000  3.40  5.425  10.56250
NumTransactions 220.0  7.900000  2.799054  2.00000  6.0000  8.00  10.000  16.00000
AvgBasketValue 220.0  178.205705  59.308471  32.55625  142.1875  173.63  215.275  324.90625
```

Penjelasan :

Fungsi `iqr_cap` = deteksi outlier pakai rumus IQR, lalu potong (`clip`).

Diterapkan ke semua kolom numerik (kecuali ID).

Hasil `describe()` menunjukkan nilai maksimum jadi masuk akal (tidak lagi ratusan/seribuan ekstrem).

6. Encoding Kategorial

Encoding Kategorikal (One-Hot)												
	CustomerID	Age	AnnualIncome	SpendingScore	TenureYear	NumTransactions	AvgBasketValue	Gender_Male	City_Gresik	City_Malang	City_Sidoarjo	City_Surabaya
0	1	19.0	13.9	67.0	6.2	12.0	206.00	True	True	False	False	False
1	2	19.0	44.8	59.0	5.3	9.0	210.38	False	True	False	False	False
2	3	26.0	18.9	53.0	8.0	15.0	190.63	False	False	False	False	True
3	4	30.0	64.5	17.0	3.9	7.0	125.28	False	False	False	True	False
4	5	35.0	75.6	59.0	10.1	13.0	118.31	True	False	False	False	True

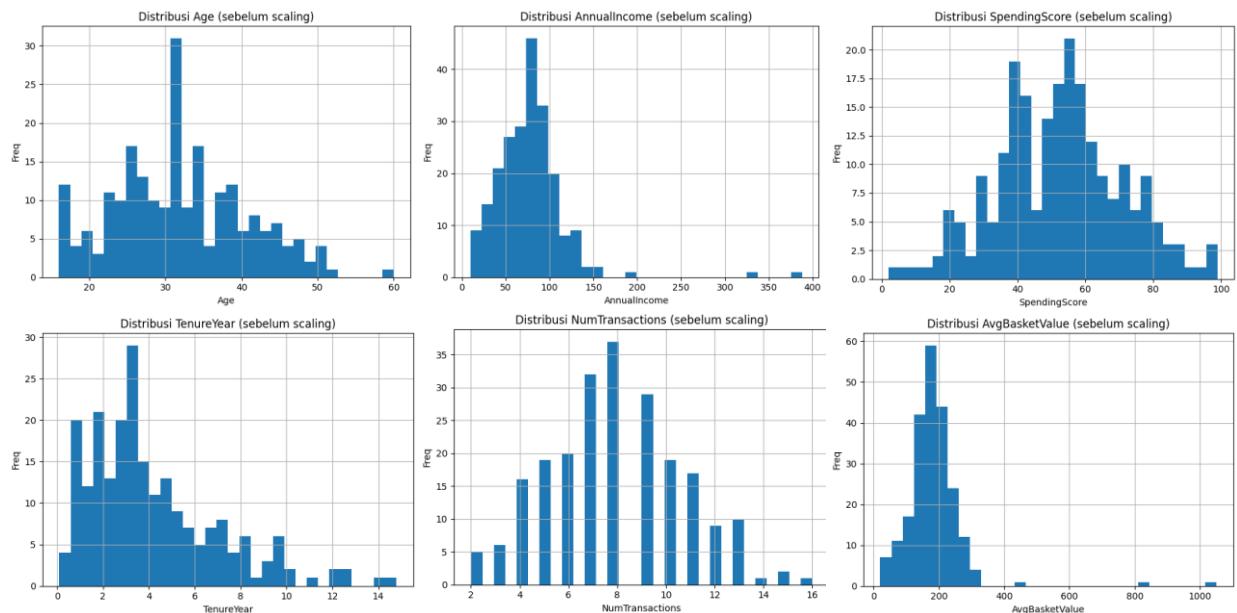
Penjelasan : mengubah kolom kategorial seperti gender dan city, menjadi binery(1/0)

Jadi misal, jika gender_male True maka gender_female false dan sebaliknya.

Lalu untuk city, misal dia tinggal di Surabaya, maka city_Surabaya True dan city_ yang lain false

7. Visualisasi Distribusi sebelum Scaling/Sebelum Normalisasi

```
plot_cols = ['Age', 'AnnualIncome', 'SpendingScore', 'TenureYear', 'NumTransactions', 'AvgBasketValue']
for c in plot_cols:
    plt.figure()
    df[c].hist(bins=30)
    plt.title(f"Distribusi {c} (sebelum scaling)")
    plt.xlabel(c), plt.ylabel("Freq")
    plt.tight_layout()
    plt.savefig("data.png")
    plt.show()
```



8. Simple Feature Scalling

$$(x / \max(x))$$

1) Simple Feature Scaling ($x / \max(x)$)												
	CustomerID	Age	AnnualIncome	SpendingScore	TenureYear	NumTransactions	AvgBasketValue	Gender_Male	City_Gresik	City_Malang	City_Sidoarjo	City_Surabaya
0	1	0.341573	0.090172	0.676768	0.586982	0.7500	0.640185	True	True	False	False	False
1	2	0.341573	0.290626	0.595960	0.501775	0.5625	0.647510	False	True	False	False	False
2	3	0.467416	0.122608	0.535554	0.757396	0.9375	0.586723	False	False	False	False	True
3	4	0.539326	0.418424	0.171717	0.369231	0.4375	0.385588	False	False	False	True	False
4	5	0.629213	0.490431	0.059560	0.956213	0.8125	0.364136	True	False	False	False	True

Penjelasan :

Supaya semua fitur punya skala yang sama (0–1).

Tidak ada fitur yang mendominasi hanya karena angkanya lebih besar.

Contoh: tanpa scaling, "AnnualIncome" (max 154) bisa jauh lebih berpengaruh daripada "TenureYear" (max 14).

9. Min Max Scaling

2) Min-Max Scaling (0..1)

```
def minmax_scaling(x: pd.Series):
    mn, mx = x.min(), x.max()
    return (x - mn) / (mx - mn) if mx != mn else x

mn = df_encoded.copy()
for c in plot_cols:
    mn[c] = minmax_scaling(mn[c])

mn.head()
```

CustomerID Age AnnualIncome SpendingScore TenureYear NumTransactions AvgBasketValue Gender_Male City_Gresik City_Malang City_Sidoarjo City_Surabaya
0 1 0.075710 0.027055 0.665359 0.583035 0.714286 0.600115 True True False False False
1 2 0.075710 0.241415 0.581699 0.497013 0.500000 0.608256 False True False False False False
2 3 0.252366 0.061741 0.518954 0.755078 0.928571 0.540700 False False False False True True
3 4 0.353312 0.378708 0.142484 0.363202 0.357143 0.317167 False False False True True False
4 5 0.479495 0.455082 0.581699 0.955795 0.785714 0.293326 True False False False True True

Penjelasan :

Ambil nilai minimum (mn) dan maksimum (mx) dari kolom.

Min-Max Scaling membuat semua kolom numerik punya rentang 0–1

10. Z Score

3) Z-Score Standardization

```
def zscore(x: pd.Series):
    mu, sd = x.mean(), x.std(ddof=0)
    return (x - mu) / sd if sd != 0 else x

zs = df_encoded.copy()
for c in plot_cols:
    zs[c] = zscore(zs[c])

zs.head()
```

CustomerID Age AnnualIncome SpendingScore TenureYear NumTransactions AvgBasketValue Gender_Male City_Gresik City_Malang City_Sidoarjo City_Surabaya
0 1 -1.496983 -2.009544 0.793341 0.803072 1.468121 0.503507 True True False False False
1 2 -1.496983 -0.999740 0.360738 0.642993 0.398866 0.548728 False True False False False
2 3 -0.681790 -1.846145 0.036286 1.483230 2.542356 0.209964 False False False False True True
3 4 -0.220138 -0.355949 -1.910428 -0.066019 -0.322270 -0.894415 False False False True True False
4 5 0.356929 0.006796 0.360738 2.276747 1.826199 -1.012204 True False False False True True

Penjelasan :

$\mu = \text{x.mean()}$ → ambil rata-rata dari kolom.

$sd = \text{x.std(ddof=0)}$ → ambil standar deviasi dari kolom

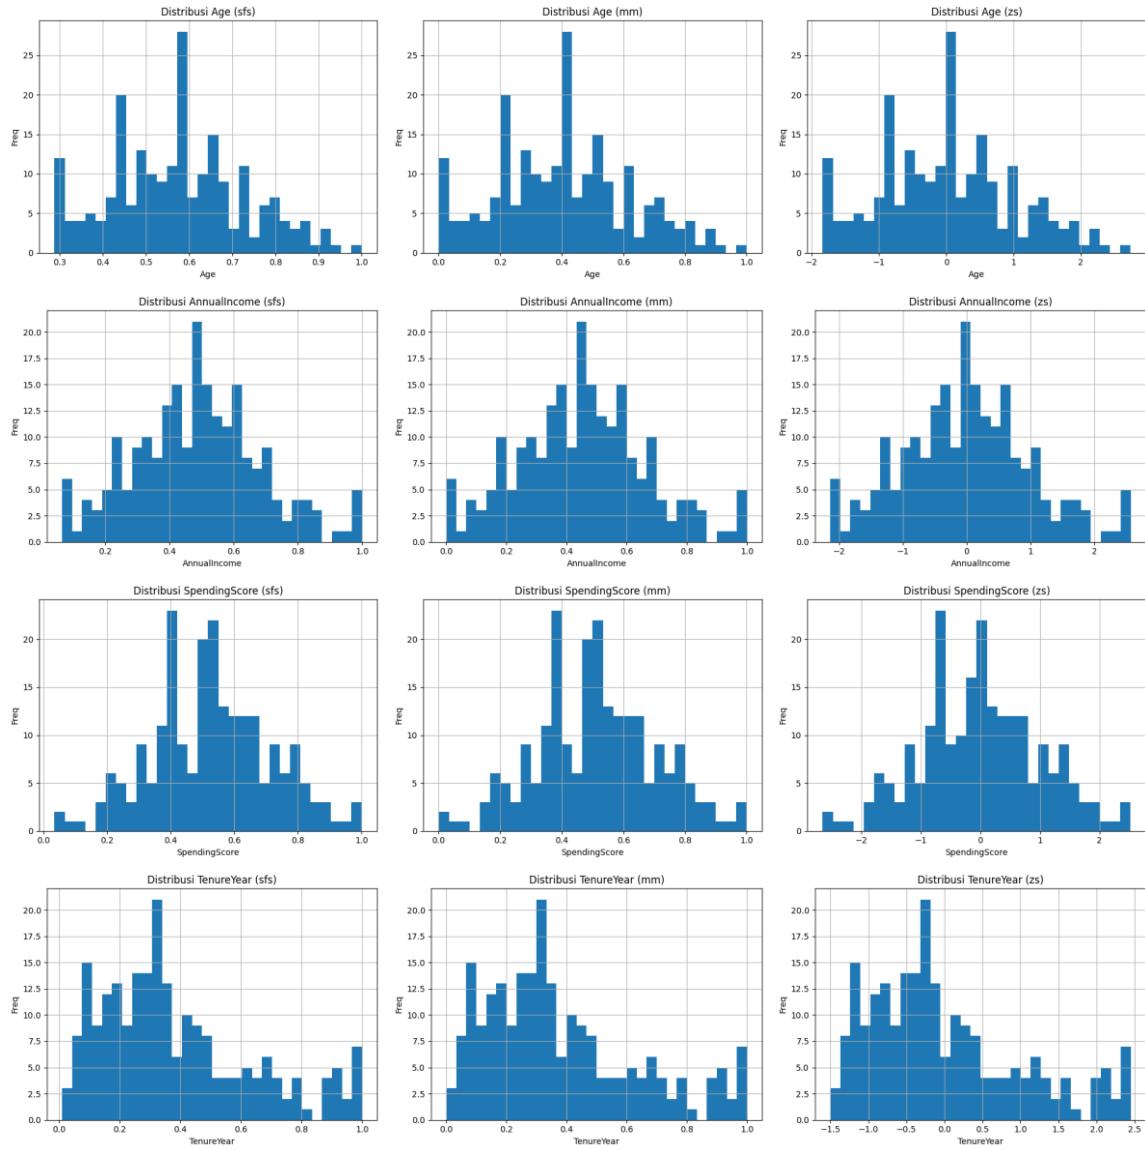
$zs = \text{df_encoded.copy()}$ → buat salinan dataset.

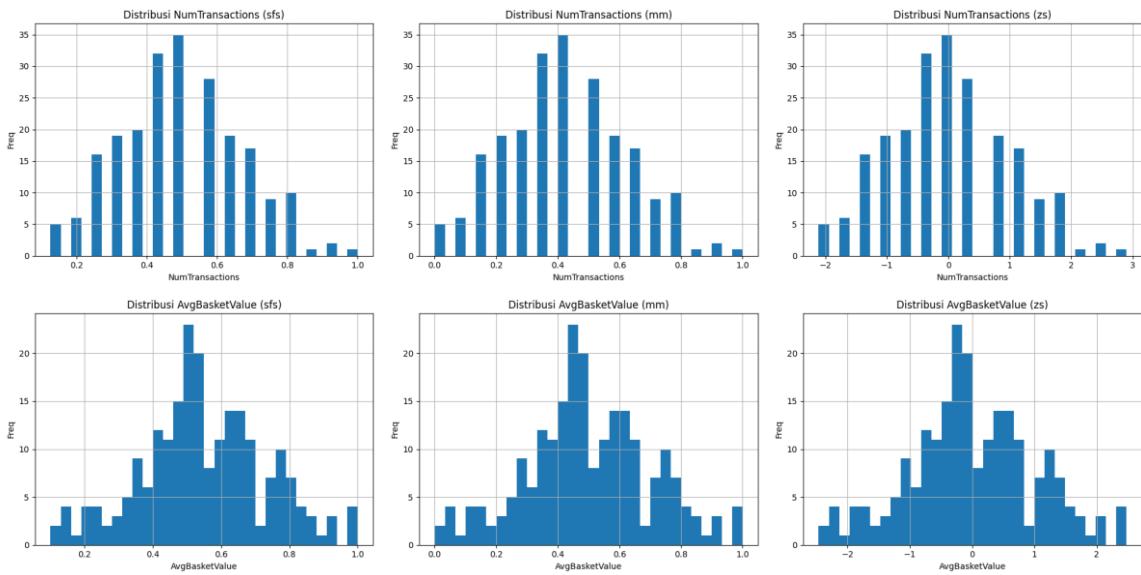
$plot_cols = \text{daftar kolom numerik (Age, AnnualIncome, SpendingScore, dsb).}$

Z-Score menormalkan data → rata-rata = 0, deviasi standar = 1.

11. Visualisasi Distribusi sesudah Scaling / Normalisasi

```
for c in plot_cols:
    for name, frame in [("sfs", sfs), ("mm", mm), ("zs", zs)]:
        plt.figure()
        frame[c].hist(bins=30)
        plt.title(f"Distribusi {c} ({name})")
        plt.xlabel(c); plt.ylabel("Freq")
        plt.tight_layout()
        plt.savefig("distribusi.png")
        plt.show()
```





12. Perbandingan nilai Head

Perbandingan Nilai (Head)

```

compare = pd.DataFrame({
    'Asli_Age': df['Age'].head(10).values,
    'SFS_Age': sfs['Age'].head(10).values,
    'MM_Age': mm['Age'].head(10).values,
    'ZS_Age': zs['Age'].head(10).values
})
compare

```

✓ 0.0s

	Asli_Age	SFS_Age	MM_Age	ZS_Age
0	19.0	0.341573	0.075710	-1.489683
1	19.0	0.341573	0.075710	-1.489683
2	26.0	0.467416	0.252366	-0.681790
3	30.0	0.539326	0.353312	-0.220138
4	35.0	0.629213	0.479495	0.356929
5	45.0	0.808989	0.731861	1.511061
6	40.0	0.719101	0.605678	0.933995
7	31.0	0.557303	0.378549	-0.104724
8	32.0	0.575281	0.403785	0.010689
9	23.0	0.413483	0.176656	-1.028030